Transformer-AdamW 局部涨落-响应研究手册 v2.0

吸收 8.11 旧实验后的实验室工位重构方案

目标：从 native AdamW 重新测量 spontaneous fluctuation 与 causal impulse response 的关系

适用：MiniMind / Transformer 预训练；新工位电脑独立仓库

核心原则：不预设 FDT 成立，不预设 250M 是相变点，不把 V2A/V2B 当作新实验主干。先测量，再因果，再泛化，最后才控制。

1. 这次为什么需要对旧方案做结构性修改

旧 v1 方案的大方向是正确的：从同一完整 AdamW 状态出发，区分自然随机涨落和人工小扰动响应，并要求跨 seed / 训练位置验证。但 8.11 暴露出四个必须正式进入协议的因素：方向异质性、有限记忆 washout、廉价状态信号的 held-out 失败，以及平均收益与尾部风险可能冲突。

因此新版不是推翻原计划，而是把“B → χ”主线做得更严格：训练位置不再被提前命名为确定 Phase；人工响应从单一 mean loss 扩展到参数响应、平均功能响应和尾部功能响应；正式控制前增加方向审计和 tail gate。

1.1 8.11 已经支持什么

- 在冻结单 seed / 单 checkpoint 的短程设置里，改变 AdamW 的历史梯度记忆方式能够产生可测的局部响应。
- 关闭快记忆驱动后约 84.24% 优势洗脱，说明效应主要依赖持续动力学驱动，而非永久轨迹跃迁。
- 模块效应明显异质，说明 susceptibility 很可能依赖方向 q。
- 强脉冲不等价于持续低剂量，说明剂量和时间尺度都重要。
- 平均 loss 改善可能伴随 CVaR99 恶化，因此平均指标不能独占裁决。

1.2 8.11 没有支持什么

- 没有直接测量 spontaneous fluctuation B 与 causal susceptibility χ 的关系。
- 没有 ±ε 中心差分，因此不能证明局部线性/奇对称 response。
- V2A 是持续 memory-kernel intervention，不是单步 impulse。
- 主要证据来自单 seed、单 checkpoint，不能证明跨轨迹规律。
- 旧 χ/Q 的 held-out 失败不能等同于新 B→χ 被证伪，因为二者不是同一变量。

2. 旧 8.11 代码要不要带到实验室

结论：不需要旧代码才能开始。科学实验建议新建仓库，从 native AdamW 干净起跑；旧代码只择优移植已审计的基础工具。

2.1 建议继承的工程经验

- checkpoint 完整恢复与 resume 检查
- optimizer m/v/step 状态审计
- RNG snapshot / restore / hash
- no-op 路径 bitwise 或 near-bitwise 对齐
- frozen-gradient correctness test 与参数增量误差定位
- protocol hash / RUN_CONFIG / source-of-truth 记录方式
- 后期工程计时的 paired / ABBA 思路

2.2 不建议直接迁移的旧主逻辑

- dual-memory fast state 与 V2A 主优化器

- legacy fast bootstrap
- V2B χ/Q controller
- sleep/wake sentinel
- module gate / sparse coalition
- strong heat pulse
- 旧 Phase classifier 与把 gradient norm 命名为 temperature 的路径

原因不是这些旧代码“没价值”，而是它们会给新 baseline 引入多余状态与自由度。新实验需要回答 native AdamW 的基础响应问题，越干净越好。

3. 训练位置：从“Phase 标签”改成“位置采样”

旧分析提示训练早晚存在波动差异，但 8.11 的变量身份审计已经说明旧 Phase 边界不能被视为可跨设置冻结的确定相变。因此新版只预先定义训练位置，不定义物理相。

位置	建议相对进度	含义
EARLY	10%-15%	强非平稳早期
CROSSOVER_CANDIDATE	25%-35%	旧转折附近，仅作候选
MID	60%-70%	中后期
LATE	85%-95%	后期低速演化区

如果沿用约 1B token 预算，可近似选 100M / 250M / 650M / 950M，但报告必须写实际 token。是否存在 dynamical crossover，应由新的 fluctuation、susceptibility、response relaxation 等结果反向验证。

4. 新实验的核心动机：为什么既要自然涨落，又要人工扰动

自然 batch 的变化会同时改变高维梯度的许多坐标。即使发现 q 方向梯度偏大时未来 loss 更好，也不能证明“主动沿 q 多走一点”会更好，因为自然事件还伴随着其它方向、范数、数据组成与 AdamW m/v 的共同变化。

人工 ±ε 脉冲的作用就是隔离因果：同一完整 checkpoint、同一 future batch、同一 RNG，只改当前梯度在 q 方向的一点点。随后测未来 1/8/32 步变化。

真正的科学问题：自然训练中的 spontaneous fluctuation 是否包含关于 causal intervention response 的信息，而不是“某个温度指标是否好看”。

5. 数学建模

5.1 完整状态

$$Z_t = (\theta_t, m_t, v_t, data_state_t, rng_state_t, amp_state_t, t)$$

$$Z_{t+1} = F_t(Z_t, u_t, \omega_{t+1})$$

这一定义承认 AdamW 的记忆、数据状态和随机状态都是未来演化的一部分，不需要假设平衡、凸性或高斯热噪声。

5.2 冻结方向 q

$$g_{probe} = \nabla_\theta L_{probe}(\theta_t)$$

$$q = \frac{g_{probe}}{\|g_{probe}\|_2 + \varepsilon_q}$$

probe 来自训练分布的独立固定 pool，与正式 eval 分离。第一版 primary 使用 full-model q；random q 是负对照，模块 q 用于方向异质性诊断。

5.3 自然涨落

```
s_r = <q, g_t^(r)>
delta_s_r = s_r - mean_r(s_r),    sigma_q = Std_r(s_r)
```

不同 r 代表从同一 Z_t 出发的不同 future random stream。除标准差外，还记录 MAD、skewness、kurtosis、p95/p99 和 clipping-conditioned 分布。

5.4 未来 observables

```
X_theta(r,H) = <q, theta_{t+H}^(r) - theta_t>
Y_mean(r,H)  = L_eval(theta_t) - L_eval(theta_{t+H}^(r))
Y_tail(r,H)  = CVaR99_t - CVaR99_{t+H}^(r)
```

参数响应用于先判断局部动力学是否可预测；mean/tail 用于判断这种动力学信息是否真正传递到功能表现。

5.5 自然关系 B

```
B_H^Y = Cov_r(delta_s_r, Y_r,H) / (Var_r(delta_s_r) + eps_B)
```

B 只是 observational slope，不是因果响应。

5.6 单步 ±epsilon 脉冲与 susceptibility

```
g_plus  = g + epsilon*q
g_minus = g - epsilon*q
epsilon = rho * sigma_q
chi_H^Y = ( E[Y_plus,H] - E[Y_minus,H] ) / (2*epsilon)
```

人工扰动只在一个 optimizer step 注入，之后恢复 native AdamW。中心差分同时用于估计 response 和检查 +ε/-ε 的局部奇对称。

5.7 最终检验

```
chi_{t,H}  ?=  f_H(B_{t,H}, Z_t, q)
```

第一版从最简单线性映射开始，但允许训练位置与方向交互。目标不是强行得到一个全局 K，而是确认是否存在可泛化的 local/state-dependent relation。

6. “组间随机、组内锁定”

不同 stream 之间使用不同数据顺序和随机流，用来采样系统自然波动；同一 stream 内 baseline / plus / minus 使用完全相同的 future batches、dropout RNG 和其它可控随机性。

```
stream r:  baseline / plus / minus share the same omega_r
```

口诀：组间放开随机性，组内锁定随机性。这样 plus-minus 的差才主要是 perturbation，而不是 batch 运气。

7. 新版实验决策树

- E0 native baseline + deterministic replay → 失败：先修工程，不做科学结论
- E1 natural batch fluctuation 可稳定测量？ → 失败：改一次观测尺度/方向，仍无则停止
- E2 ±epsilon 有局部线性 impulse response？ → 失败：缩小 epsilon 一次，仍无则简单线性 FR 不适用
- E3 response 是否方向依赖？ → 方向依赖是结果，不是失败
- E4 natural B 能否预测 causal chi？ → 失败：进入 AdamW memory / 高维耦合 / 非平稳定位
- E5 held-out seed 是否还能预测，且优于 progress/LR/loss/grad-norm baseline?
- Mean response 与 tail response 是否一致？ → tail 恶化则禁止控制
- E7 只有上述全部通过后才允许在线小幅控制。

8. 具体执行计划

8.1 Day 0：新工位环境

1. 建立全新 fr_minimind_lab 仓库
2. 冻结 MiniMind commit、数据版本、tokenizer 与训练配置
3. 记录 GPU/driver/CUDA/PyTorch/precision
4. native AdamW smoke
5. 确认已有 checkpoint 是否包含 optimizer m/v/step；没有就生成新的完整 baseline checkpoints

8.2 E0：replay audit

同 checkpoint + 同 stream + action=0 的两条 branch 跑 32 step。要求 batch manifest、RNG hash、loss、参数和 optimizer state 在确定性能力允许范围内一致。rho=0 的 perturbation 路径必须 no-op。

8.3 E1：自然涨落 pilot

只做 1 seed × MID × R=16，只跑 baseline。先确认 sigma_q 非零、分布可测，eval-probe 的 mean/tail 噪声不会把 branch 差异完全淹没。

8.4 E2：epsilon scan

建议 rho={0.10,0.25,0.50,1.00}。如果全部非线性，再缩到 {0.025,0.05,0.10} 做一次最后 pilot。只为冻结线性区，不为挑最好 loss。

8.5 E3：方向审计

先 full-model q 对比 norm-matched random q；预算允许再加入 V/O、MLP Down、Q/K、Gate/Up。模块结果只作为 χ(q) 的结构诊断。

8.6 E4：Discovery

推荐 3 discovery seeds × 4 positions × R=16 × 3 branches × 32 steps。一条 rollout 同时记录 H=1/8/32。主要输出 B_theta/B_mean/B_tail、chi_theta/chi_mean/chi_tail、odd-symmetry error，以及 response 随 H 的衰减或符号反转。

8.7 E5：Frozen holdout

查看 holdout seed 前冻结 q、rho、eval-probe、tail 定义、拟合模型和成功门槛。关键判断不是“相关系数显著”，而是 B 是否在 held-out seed 上比训练进度、LR、当前 loss、grad norm 等简单 baseline 多提供 response 预测信息。

8.8 E6：失败后机制定位

优先做 gradient pulse vs parameter pulse。Gradient pulse 会把扰动写入 AdamW m/v；Parameter pulse 保持 baseline m/v，只对参数施加等效小位移。若后者稳定而前者不稳定，optimizer memory/preconditioning 就成为明确候选破坏源。

8.9 E7：最后才控制

只有 held-out 预测通过且 mean/tail 不冲突，才允许按照预测 chi 做小幅控制；幅度必须始终位于已验证的线性区。

9. 统计层级：避免重复旧实验的外推问题

在一个固定 state 内，random stream 是局部重复单位，baseline/plus/minus 是配对观测；跨轨迹泛化时，training seed 是更高层独立单位。多个 checkpoint 属于 seed 内相关观测。validation token/sample 数量不能被当成独立训练重复。

因此 8.11 的单 seed 95% CI 可以说明冻结局部效应测得较精确，但不能直接证明跨 seed 规律。新版 state-level 用 paired bootstrap over streams，泛化层用 held-out seed / leave-one-seed-out。

10. 8.11 代码迁移的最终建议

推荐：新工位从头搭建科学主干；如果旧代码方便取得，只审计后搬 checkpoint/RNG/correctness/protocol 工具。

这样做的好处是：新实验的每一条 branch 都能明确证明自己来自 native AdamW；不会因为 fast-state、legacy/strict 分支或旧控制器状态而产生“baseline 到底是不是 baseline”的争议。

11. 结果前景与对应结论

结果	可允许结论	下一步
跨 seed B→chi，mean/tail 一致	存在可泛化的 local empirical FR	才进入小幅控制

只在 Late/特定方向成立	state/direction-dependent local FR	研究 dynamical crossover / direction
只预测 theta response	动力学层 FR，不外推泛化	研究参数→泛化断层
chi 可测但 B 不能预测	spontaneous fluctuation 与 intervention response 分离	AdamW memory / high-D / nonstationarity
足够小 epsilon 仍无局部线性	简单 linear-response 近似不适用	停止或转非线性机制

12. 最终建议

这次实验室重做的目标不是复现 V2A，也不是证明旧 8.11 错。8.11 应作为先验和方法学教训：局部 response 可能存在、可能有限时、可能方向依赖；简单状态预测可能失败；平均收益可能掩盖尾部代价。

新实验要把这些现象收束成一个更基础的问题：

```
spontaneous fluctuation B   ---> ?   causal impulse response chi
```

并严格回答：它在哪个训练位置、哪个方向、哪个时间尺度成立或失效。只有这一步完成以后，后续“物理指导优化”才真正有因果基础。